深層学習の基礎理論 (3)— 本体資料 P20∼P26
２０２２年１１月２２日

高山 幸秀
立命館大学理工学部数理科学科

Abstract. １９９０年代に一度は下火になったニューラルネットが、近年、多層ネットによるディープラーニング（以下、深層学習）として復活し、AI の新技術として爆発的発展を遂げた。現在、さまざまなアプリケーションの開発が盛んに行われているが、技術的限界も次第に明らかになってきており、深層学習技術を補完、あるいはこれを超える全く新しい技術の提案も始まっている。このような状況において、今一度ニューラルネットや深層学習の基本原理を押さえておくこは意味のあることと考えられる。本講座では、主にこの方面を専攻していない学生諸君を念頭に、深層学習の基礎理論うち、入門的な部分について講述する。

Contents

1. 前回までのあらすじ 2
2. 誤差逆伝播法（つづき) 2
2.1. 勾配消失問題/解決法 2
3. 自己符号化器 4
3.1. 自己符号化器 4
3.2. ディープネットの事前学習 4
4. 結語— この部分本体資料にはありません 6

Date: 2022 年 10 月 19 日、11 月 8 日、11 月 22 日、徳島大学工学部集中講義.

1. 前回までのあらすじ

深層学習（ディープラーニング）は、多層パーセプトロンと呼ばれる、ユニットを集めた層を何段も積み重ね、下の層から上の層へ信号を伝播させて情報処理するシステムによって実現される。その性能の良し悪しは各層の間の信号に付与される重み付けや入力信号の強さを調節するバイアスデータといったパラメータをうまくチューニングできるかどうかに依存する。そのチューニングとは、訓練データによって誤差関数の値を、さらい誤差関数の勾配ベクトルを計算し、その勾配ベクトル値を何倍かしたものを元のパラメータから引くことによって行われた。誤差関数の勾配は個々のパラメータ w_i による 1 階偏微分値だが、w_i あ g 出力層から遠い層のパラーメータの場合、偏導関数の計算は Chain rule を何度も使って計算する必要があり、そのために誤差逆伝播法という効率的なアルゴリズムが開発された。

2. 誤差逆伝播法（つづき)

2.0.1. 参考 1 . 誤差逆伝播法アリゴリズムでは、$\delta_j^{(\ell)}$ を再帰的に計算するわけですが、ある種の問題については、これが簡単な形になることを数学的に示すことができます。ここでは、回帰問題、二値問題、多クラス問題についての結果を示しています。

2.0.2. 参考 2 . ここでは、これまでの話が全て数学の言葉を使って一般的に書き表せることを示しています。詳細は理解できなくても、深層学習の原理というのは、基本的には数学なのだという事が、見てとれれば良いです。

2.1. 勾配消失問題/解決法.

- 誤差関数の勾配 $\nabla E(\overline{w})$ は、一階偏微分を使って定義されていましたが、これでは精度が荒くどうしても誤差が大きくなてしまいます。各層での誤差が積み重なるので、多層パーセプトロンの段数を上げると、誤差が沢山蓄積します。しかし、多層パーセプトロンは段数を上げないと良い性能が出ず、実用化に向かなくなってしまうという、ジレンマに陥ります。

- すなわち、誤差逆伝播法アルゴリズムでは、出力層の第 L 層の $\delta_k^{(L)}$ を使って、1 つ下の第 $L-1$ 層の $\delta_k^{(L-1)}$ を計算し、それを使ってもう 1 つ下の第 $L-2$ 層の $\delta_k^{(L-2)}$ を計算し、、、という風に繰り返し、最終的に入力層の $\delta_k^{(1)}$ で止まるまで計算し、それらを使って第 ℓ 層のパラメータ $w_{ji}^{(\ell)}$ に関する勾配 $\partial E/\partial w_{ji}^{(\ell)}$ を計算するのですが、各 ℓ について $\delta_k^{(\ell)}$ を計算したときに誤差が入り込むので、各層の誤差が積み重なってしまいます。すると、勾配 $\nabla E(\overline{w})$ が急激に大きくなったり、逆に零になったり（勾配消失）が起こります。こうなると、パラメータ $\overline{w}$ をうまく更新することができなくなります。

- 結局、勾配消失問題、すなわち、誤差の良い修正値を正確に決められないという問題が解決できず、段数の多い実用的な多層パーセプトロンが上手く作れなかったことが、ニューラルネット研究が一時期「絶滅状態」に陥った理由のようです。

- それを解決したのが、自己符号化器なるものを使う「事前学習」というアイディアで、それが現在の「深層学習 (deep learning)」技術の出発点になっています。

- 特に計算機科学業界では、流行の分野にどっと人が集まり、実用化を目指して活発に研究するのですが、例えば「勾配消失問題」などの根本的な問題が明らかになってくると、皆研究を諦めて撤退し、次の流行に飛びつく傾向があります。しかしながら、「深層学習」技術は皆が撤退した後もしぶとく粘って研究を続けていた孤高（？）の研究者の発見によってもたらされたようです。

- １９８０年代に隆盛を極めた数理論理学に基づく知識情報処理アプローチの人工知能研究も、２０００年頃までにははほとんどの研究者が撤退し（私もその一人です)、今やほぼ絶滅した分野のようになっています。しかし、しぶとく粘っている研究者が居て、また復活させてくれないかしら？ と虫の良いことを考えたりもします。

3. 自己符号化器

ここでは、「勾配消失問題」を解決して、絶滅寸前のニューラルネット技術を「深層学習技術」として復活させた、「ディープネットの事前学習」のアイディアを簡単に紹介します。

3.1. 自己符号化器.

- 「ディープネットの事前学習」では「自己符号化器」と言うものが使われます。

- これは図にあるように、入力 $\overline{x}$ を第１層で受け取って、第２層で出力 $\overline{y}$ を出力する２層ネットを考えます。第１層から第２層への信号の重み付けとバイアスデータ全体は行列 $\mathbb{W}$ とベクトル $\mathbf{b}$ で表されています。活性化関数を f として、この２層ネットの入出力は
$$\overline{y}(\overline{x}) = f(\mathbb{W}\overline{x} + \mathbf{f})$$
と表されます。

- この２層ネットを２つもってきて、２つ目のものは入力と出力を逆にして最初の２層ネットと連結します。

- すると、出来上がった３層ネットは、原理的には
$$\underbrace{\overline{x} \quad \longmapsto}_{\text{１番目の２層ネット}} \quad \overline{y}(\overline{x}) \qquad \underbrace{\longmapsto \quad \overline{x}}_{\text{入出力を逆にした２番目の２層ネット}}$$
のように恒等関数になっているはずです。

- そして、実際にそうなるように確率的勾配降下法などを使ってパラメータ $\mathbb{W}, \mathbf{b}$ をチューニングします。この「学習」は訓練データを使わないので、「教師なし学習」と呼ばれます。こうやって作られたものを自己符号化器と呼びます。

3.2. ディープネットの事前学習.

- ここでは、自己符号化器をつかった「ディープネットの事前学習」のアイディアを紹介します。

- まず多層パーセプトロンを用意します。ここでは４層ネットの例で考えています。各層の間の重み付けやバイアスは、全部纏めて行列 $\mathbb{W}^{(\ell)}$, （$\ell = 2, 3, 4$）で表してます。

- **Step 1** では、まず第２層と第３層（つまり中間層）のコピーを１つずつ作り、(A) 第１層と第２層のコピー、(B) 第２層と第３層のコピー、(C) 第３層と第４層の３つの２層ネットを作ります。そして
  (1) まず (A) の２層ネットで自己符号化器を作って、第１層の入力を使って教師なし学習をします。これによって $\mathbb{W}^{(2)}$ が　チューニングされます。
  (2) 次に (B) の２層ネットで同様に自己符号化器を作って「教師なし学習」をさせるのですが、この時の入力データとしては、(A) の２層ネットの入力 $\overline{x}$ に対して出力された $\overline{z}^{(2)}$ を使います。これによって $\mathbb{W}^{(3)}$ がチューニングされます。
  (3) さらに (C) の２層ネットの教師なし学習で $\mathbb{W}^{(4)}$ をチューニングするのですが、この時の自己符号化器に使う入力データは、$\overline{x}$ を (A) に食わせて、その出力

$\overline{z}^{(2)}$ が (B) に食わされて、そこから出力された $\overline{z}^{(3)}$ を使います。

- **Step 2** では、最初の４層ネットに戻すのですが、この時パラーメータ $\mathbb{W}^{(\ell)}$ は **step 1** でチューニングされたものを使います。これが「事前学習された多層ネット」なわけです。

- **Step 3** それから先は、訓練データを使って「教師あり学習」をしてチューニングします。

- このように、「事前学習」によってあらかじめある程度チューニングしておけば、訓練データや誤差関数の勾配を使った学習をする際も、誤差の誤差が沢山蓄積して勾配消失が起こってしまうことがなく上手く行くというわけです。しかし **Remark** に書かれているように、何故これで上手く行くのかは、経験的に分かっているだけで、数学理論として原理的にこうだからだ！ ということは分かっていないようです。

4. 結語— この部分本体資料にはありません

「深層学習」とは、要するにパターン認識です。私よりも一世代上の研究者は人工知能研究として簡単な図形の認識や文字列の認識技術を研究していましたが、当時のアプローチでは成功しなかったようです。私の世代で、人工知能は図形や文字列といった論理的意味のないものを扱うのではなく、もっと知的なコンピュータ技術であるべきだという話になり、数理論理学に基づく知識情報処理のアプローチで盛んに研究が行われましたが、やはりあまり成功しなかったわけです。ところがニューラルネット、さらに深層学習というアイディアが出てきて、忘れ去られていたパターン認識技術が飛躍的に進歩し、それが現在の人工知能技術として実用化に成功しました。

まあ、人工知能研究はそんな風に進んできているので、パターン認識の進化形である現在の人工知能に、「自分が認識したパターンの意味を理解する」機能が欲しくなってきます。パターンを認識して、それだけにとどまらず、さらにそれの意味を理解して高度に知的は情報処理を行う。そんなシステムのための技術開発は、もう既に世界のどこかで始まっているのかも知れません（私は知りませんけど）。

Yukihide Takayama, Department of Mathematical Sciences, Ritsumeikan University, 1-1-1 Nojihigashi, Kusatsu, Shiga 525-8577, Japan

Email address: takayama@se.ritsumei.ac.jp